Московский государственный технический университет им. Н.Э. Баумана Кафедра «Системы обработки информации и управления»

Лабораторная работа №2 по дисциплине «Методы машинного обучения» на тему «Изучение библиотек обработки данных»

Выполнил: студент группы ИУ5-21М Якубов А. Р.

1. Цель лабораторной работы

Изучить библиотеки обработки данных Pandas и PandaSQL [1].

2. Задание

Задание состоит из двух частей [1].

2.1. Часть 1

Требуется выполнить первое демонстрационное задание под названием «Exploratory data analysis with Pandas» со страницы курса mlcourse.ai.

2.2. Часть 2

Требуется выполнить следующие запросы с использованием двух различных библиотек — Pandas и PandaSQL:

- один произвольный запрос на соединение двух наборов данных,
- один произвольный запрос на группировку набора данных с использованием функций агрегирования.

Также требуется сравнить время выполнения каждого запроса в Pandas и PandaSQL.

3. Ход выполнения работы

3.1. Часть 1

Ниже приведён демонстрационный Jupyter-ноутбук «Exploratory data analysis with Pandas» курса mlcourse.ai (файл assignment01 pandas uci adult.ipynb).

```
In [89]: import numpy as np
        import pandas as pd
        pd.set_option('display.max.columns', 100)
        pd.set_option("display.width", 70)
        import matplotlib.pyplot as plt
        import seaborn as sns
```

Подключение предлагаемой выборки и проверка выводом первых пяти записей:

```
Out[90]:
                                          education education-num \
                       workclass fnlwgt
           age
            39
                       State-gov 77516
                                          Bachelors
                                                               13
        1
          50
                Self-emp-not-inc 83311
                                          Bachelors
                                                               13
                        Private 215646
        2
            38
                                            HS-grad
                                                                9
                                               11th
                                                                7
        3
            53
                         Private 234721
                         Private 338409
            28
                                          Bachelors
                                                               13
```

```
marital-status
                                 occupation
                                                relationship
                                                                 race
0
                               Adm-clerical
                                               Not-in-family
         Never-married
                                                                White
1
    Married-civ-spouse
                            Exec-managerial
                                                     Husband
                                                                White
2
              Divorced
                          Handlers-cleaners
                                               Not-in-family
                                                                White
                          Handlers-cleaners
3
    Married-civ-spouse
                                                     Husband
                                                                Black
                             Prof-specialty
                                                         Wife
4
    Married-civ-spouse
                                                                Black
            capital-gain
                           capital-loss
                                          hours-per-week
       sex
0
      Male
                     2174
                                       0
                                                       40
1
      Male
                        0
                                       0
                                                       13
2
      Male
                        0
                                       0
                                                       40
3
      Male
                        0
                                       0
                                                       40
4
    Female
                        0
                                       0
                                                       40
   native-country
                   salary
0
   United-States
                     <=50K
1
    United-States
                     <=50K
2
   United-States
                    <=50K
3
    United-States
                     <=50K
4
             Cuba
                     <=50K
```

1. How many men and women (sex feature) are represented in this dataset?

4-5. What are the mean and standard deviation of age for those who earn more than 50K per year (salary feature) and those who earn less than 50K per year?

0.000000%

6. Is it true that people who earn more than 50K have at least high school education? (education – Bachelors, Prof-school, Assoc-acdm, Assoc-voc, Masters or Doctorate feature)

7. Display age statistics for each race (race feature) and each gender (sex feature). Use groupby() and describe(). Find the maximum age of men of Amer-Indian-Eskimo race.

```
In [96]: data.groupby(["race", "sex"])["age"].describe()
Out[96]:
                                          count
                                                      mean
                                                                   std
                                                                         min
         race
                              sex
          Amer-Indian-Eskimo
                               Female
                                          119.0
                                                 37.117647
                                                             13.114991
                                                                        17.0
                                          192.0
                                                 37.208333
                                                            12.049563
                               Male
                                                                        17.0
          Asian-Pac-Islander
                               Female
                                          346.0
                                                 35.089595
                                                            12.300845
                                                                        17.0
                                                            12.883944
                               Male
                                         693.0
                                                 39.073593
                                                                        18.0
          Black
                               Female
                                         1555.0
                                                 37.854019
                                                            12.637197
                                                                        17.0
                               Male
                                         1569.0
                                                 37.682600
                                                             12.882612
                                                                        17.0
          Other
                                         109.0
                                                 31.678899
                                                            11.631599
                               Female
                                                                        17.0
                               Male
                                         162.0
                                                 34.654321
                                                            11.355531
                                                                        17.0
                                         8642.0
                                                            14.329093
          White
                               Female
                                                 36.811618
                                                                        17.0
                                        19174.0
                                                 39.652498
                                                            13.436029
                               Male
                                                                        17.0
                                         25%
                                               50%
                                                      75%
                                                            max
         race
                              sex
          Amer-Indian-Eskimo
                               Female
                                       27.0
                                              36.0
                                                    46.00
                                                           80.0
                               Male
                                        28.0
                                              35.0
                                                    45.00
                                                           82.0
          Asian-Pac-Islander
                                       25.0
                                                    43.75
                               Female
                                             33.0
                                                           75.0
                                                    46.00
                               Male
                                       29.0
                                              37.0
                                                           90.0
          Black
                               Female
                                       28.0
                                              37.0
                                                    46.00
                                                           90.0
                               Male
                                       27.0 36.0
                                                    46.00
                                                           90.0
          Other
                               Female
                                       23.0 29.0
                                                    39.00
                                                           74.0
                                                    42.00
                               Male
                                       26.0
                                              32.0
                                                           77.0
          White
                               Female
                                       25.0
                                              35.0
                                                    46.00
                                                           90.0
                                        29.0
                                              38.0
                                                    49.00
                                                           90.0
                               Male
In [97]: data[(data["race"] == "Amer-Indian-Eskimo")
              & (data["sex"] == "Male")]["age"].max()
```

8. Among whom is the proportion of those who earn a lot (>50K) greater: married or single men (marital-status feature)? Consider as married those who have a marital-status starting with Married (Married-civ-spouse, Married-spouse-absent or Married-AF-spouse), the rest are considered bachelors.

Out[97]: nan

9. What is the maximum number of hours a person works per week (hours-per-week feature)? How many people work such a number of hours, and what is the percentage of those who earn a lot (>50K) among them?

10. Count the average time of work (hours-per-week) for those who earn a little and a lot (salary) for each country (native-country).

```
In [100]: p = pd.crosstab(data["native-country"], data["salary"],
                          values=data['hours-per-week'], aggfunc="mean")
          р
Out[100]: salary
                                           <=50K
                                                       >50K
          native-country
           ?
                                       40.164760 45.547945
           Cambodia
                                       41.416667 40.000000
           Canada
                                       37.914634 45.641026
           China
                                       37.381818 38.900000
           Columbia
                                       38.684211 50.000000
           Cuba
                                       37.985714 42.440000
           Dominican-Republic
                                       42.338235 47.000000
           Ecuador
                                       38.041667 48.750000
           El-Salvador
                                       36.030928 45.000000
           England
                                       40.483333 44.533333
           France
                                       41.058824 50.750000
           Germany
                                       39.139785 44.977273
           Greece
                                       41.809524 50.625000
           Guatemala
                                       39.360656 36.666667
```

```
Haiti
                             36.325000
                                        42.750000
Holand-Netherlands
                            40.000000
                                              NaN
Honduras
                             34.333333
                                        60.000000
Hong
                             39.142857
                                        45.000000
Hungary
                             31.300000
                                        50.000000
India
                             38.233333
                                        46.475000
Iran
                            41.440000
                                        47.500000
Ireland
                            40.947368
                                        48.000000
Italy
                             39.625000
                                        45.400000
                                        41.100000
Jamaica
                             38.239437
Japan
                             41.000000
                                        47.958333
Laos
                            40.375000
                                        40.000000
Mexico
                             40.003279
                                        46.575758
Nicaragua
                             36.093750
                                        37.500000
Outlying-US(Guam-USVI-etc)
                            41.857143
                                              NaN
Peru
                             35.068966
                                        40.000000
Philippines
                             38.065693
                                        43.032787
Poland
                             38.166667
                                        39.000000
Portugal
                            41.939394
                                        41.500000
Puerto-Rico
                             38.470588
                                        39.416667
Scotland
                             39.444444
                                        46.666667
South
                            40.156250
                                        51.437500
Taiwan
                             33.774194
                                        46.800000
Thailand
                            42.866667
                                        58.333333
Trinadad&Tobago
                            37.058824
                                        40.000000
United-States
                            38.799127
                                        45.505369
Vietnam
                            37.193548
                                        39.200000
Yugoslavia
                            41.600000
                                        49.500000
```

3.2. Часть 2

Импорт pandasql:

```
In [101]: import pandasql as ps
          from timeit import default timer as timer
          pandasqldf = lambda q: ps.sqldf(q, globals())
  Загрузка двух наборов данных:
In [102]: device = pd.read_csv('data/user_device.csv')
          usage = pd.read csv('data/user usage.csv')
In [103]: device.head()
                                        platform version
Out[103]:
             use_id user_id platform
                                                             device \
              22782
                       26980
          0
                                   ios
                                                    10.2
                                                          iPhone7,2
          1
              22783
                       29628 android
                                                     6.0
                                                            Nexus 5
          2
              22784
                       28473 android
                                                     5.1
                                                           SM-G903F
          3
              22785
                       15200
                                   ios
                                                    10.2
                                                          iPhone7,2
          4
              22786
                       28239 android
                                                     6.0
                                                          ONE E1003
```

```
use_type_id
           0
                         2
                         3
           1
           2
                         1
           3
                         3
                         1
           4
In [104]: usage.head()
              outgoing_mins_per_month
Out[104]:
                                          outgoing_sms_per_month
                                                                    monthly_mb
           0
                                  21.97
                                                              4.82
                                                                        1557.33
           1
                                1710.08
                                                            136.88
                                                                        7267.55
           2
                                1710.08
                                                            136.88
                                                                        7267.55
           3
                                  94.46
                                                             35.17
                                                                         519.12
           4
                                  71.59
                                                             79.26
                                                                        1557.33
              use id
               22787
           0
           1
               22788
           2
               22789
           3
               22790
           4
               22792
```

Проведем два теста, в которых мы сравним время выполнения запросов в Pandas и PandasSQL. В первом тесте производится выполнение запроса SQL с соединением таблиц (наборов данных).

```
In [105]: t1_1 = timer()
          test1 1 = pandasqldf("""
                           SELECT *
                           FROM device JOIN usage
                           ON device.use id==usage.use id
          elapsed1_1 = timer() - t1_1
          test1_1.head()
Out[105]:
             use_id
                      user_id platform
                                         platform_version
                                                              device
          0
              22787
                        12921 android
                                                       4.3
                                                            GT-I9505
          1
              22788
                        28714 android
                                                       6.0
                                                            SM-G930F
          2
                        28714
              22789
                               android
                                                       6.0
                                                            SM-G930F
          3
              22790
                        29592
                               android
                                                       5.1
                                                               D2303
          4
              22792
                        28217
                               android
                                                       5.1
                                                            SM-G361F
             use_type_id
                           outgoing_mins_per_month
                                                     outgoing_sms_per_month
          0
                                              21.97
                                                                         4.82
          1
                        1
                                            1710.08
                                                                       136.88
          2
                        1
                                            1710.08
                                                                       136.88
          3
                        1
                                              94.46
                                                                        35.17
          4
                        1
                                              71.59
                                                                        79.26
```

```
monthly_mb use_id
                1557.33 22787
          0
          1
               7267.55 22788
          2
               7267.55 22789
          3
                519.12
                        22790
          4
                1557.33
                          22792
In [106]: t1_2 = timer()
         test1_2 = device.merge(usage)
          elapsed1 2 = timer() - t1 2
In [107]: print("Tecτ 1:\nPandasSQL - {0:.6f} c.\nPandas - {1:.6f} c.".format(
Тест 1:
PandasSQL - 0.014057 c.
Pandas - 0.003904 c.
```

Из результатов первого теста видно, что выполнение запроса SQL с соединением таблиц происходит значитально быстрее при использовании Pandas. Для полученной после соединения таблицы выполним запрос SQL с группировкой:

```
In [108]: t2_1 = timer()
          test2_1 = pandasqldf("""
                          SELECT DISTINCT
                          device, avg(monthly_mb) as avg_mb
                          FROM test1 1
                          GROUP BY device
                          """)
          elapsed2_1 = timer() - t2_1
          test2_1.head()
Out[108]: device
                     avg_mb
          0 A0001 15573.33
          1 C6603 1557.33
          2 D2303
                     519.12
          3 D5503
                     1557.33
          4 D5803
                     1557.33
In [109]: t2_2 = timer()
          test2_2 = test1_2.groupby('device').monthly_mb.mean()
          elapsed2 2 = timer() - t2 2
In [110]: print("Tecτ 2:\nPandasSQL - {0:.6f} c.\nPandas - {1:.6f} c.".format(
Тест 2:
PandasSQL - 0.008167 c.
Pandas - 0.002052 c.
```

Второй тест также показывает, что при выполнении запроса с группировкой Pandas опережает PandasSQL.

Список литературы

[1] Гапанюк Ю. Е. Лабораторная работа «Изучение библиотек обработки данных» [Электронный ресурс] // GitHub. — 2019. — Режим доступа: https://github.com/ugapanyuk/ml_course/wiki/LAB_PANDAS (дата обращения: 20.02.2019).